

Méthodes de Monte Carlo – Projet

stoehr@ceremade.dauphine.fr

- **À rendre avant 23 : 59, le 21 décembre 2022. Tout retard sera pénalisé : 1 point en moins toutes les 30 minutes à partir de 00 : 01.**
- **R est le seul langage autorisé.** Les questions nécessitant un code R sont indiquées par le symbole ♠. L'ensemble des générateurs aléatoires de la librairie de base de R sont autorisés.
- Le rapport (**nom du fichier : numero_groupe_noms, e.g., 001_Stoehr_Luciano**)
 - à rendre au format **.pdf** et doit contenir vos réponses et commentaires. Une rédaction soignée est attendue. Il est important de justifier/commenter les résultats théoriques et numériques.
 - Pour intégrer tout ou partie de votre code et des sorties dans votre rapport, vous pouvez utiliser les outils dédiés : Notebook, Rmarkdown ou \LaTeX + knitr.
 - Les graphiques doivent être soigneusement annotés et présentés (titre, couleur, légendes, ...).
- Une version du code pouvant être testée doit être fournie (**même nom de fichier**). Ce code doit
 - s'exécuter sans erreurs et permettre de reproduire l'intégralité des résultats présentés dans le rapport. Vous préciserez la graine utilisée pour les résultats obtenus.
 - être bien commenté. Il est possible qu'une explication orale vous soit demandée.
 - utiliser autant que possible les spécificités du langage (bonus pour les codes les plus efficaces).

Exercice 1. Soient X et Y deux variables aléatoires réelles indépendantes telles que

- X suit la loi gamma de densité par rapport à la mesure de Lebesgue sur \mathbb{R}_+^*

$$f(x) = \frac{1}{\Gamma(\alpha)\theta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\theta}\right), \quad \text{avec } \alpha = 3 \quad \text{et } \theta = 2.$$

- Y suit la loi de densité par rapport à la mesure de Lebesgue sur \mathbb{R}

$$g(y) = \frac{y - \mu + 2b}{4b^2} \mathbb{1}_{\{y \in [\mu - 2b, \mu]\}} + \frac{1}{2b} \exp\left(-\frac{y - \mu}{b}\right) \mathbb{1}_{\{y > \mu\}}, \quad \text{avec } \mu = -13 \quad \text{et } b = 2.$$

L'objectif de cet exercice est d'estimer

$$\delta = \mathbb{P}[X + Y > t], \quad \text{avec } t = 0.$$

Méthode Monte Carlo n°1.

1. (♠) Décrire une méthode pour simuler suivant la loi de (X, Y) et écrire le code R associé. Vous préciserez les différents calculs effectués.
2. (♠) Vérifier graphiquement que votre méthode et votre code sont corrects.
3. Écrire l'estimateur Monte Carlo \hat{p}_n de δ utilisant une suite de n variables aléatoires $(X_k, Y_k)_{k \geq 1}$ *i.i.d.* suivant la loi de (X, Y) .

4. (♠) Implémenter un code R qui fournit, pour $n = 1000$, une estimation de δ , de l'erreur quadratique moyenne de \hat{p}_n et un intervalle de confiance asymptotique bilatère pour δ au niveau 95%.
5. (♠) Vérifier empiriquement si l'hypothèse du régime asymptotique \hat{p}_n est satisfaite.
6. On note F la fonction de répartition de X . Montrer que

$$\delta = \mathbb{E}[1 - F(t - Y)],$$

et en déduire un estimateur $\hat{\delta}_n$ de δ utilisant une suite de n variables aléatoires $(U_k)_{k \geq 1}$ *i.i.d.* suivant la loi uniforme sur $[0, 1]$.

7. (♠) Implémenter un code R qui fournit, pour $n = 1000$, l'estimation $\hat{\delta}_n$, l'erreur quadratique moyenne de $\hat{\delta}_n$ et un intervalle de confiance asymptotique bilatère pour δ au niveau 95%.
8. Selon ces résultats, l'estimateur $\hat{\delta}_n$ est-il plus performant en terme de variance que l'estimateur \hat{p}_n ? Si oui, montrer qu'on a toujours $\text{Var}[\hat{\delta}_n] \leq \text{Var}[\hat{p}_n]$.

Méthode Monte Carlo n°2.

9. En utilisant la méthode de la variable antithétique, proposer un estimateur $\hat{\delta}_n^A$ de δ . Montrer que $\text{Var}[\hat{\delta}_n^A] \leq \text{Var}[\hat{\delta}_n]$.
10. (♠) Implémenter un code R qui fournit, pour $n = 1000$, l'estimation $\hat{\delta}_n^A$, l'erreur quadratique moyenne de $\hat{\delta}_n^A$ et un intervalle de confiance asymptotique bilatère pour δ au niveau 95%.

Méthode Monte Carlo n°3. On note q_ε le quantile d'ordre ε de la loi de X et on définit les fonctions :

$$\begin{aligned} h_{0,1} : \mathbb{R} &\rightarrow \mathbb{R} & \text{et} & \quad h_{0,2} : \mathbb{R} \rightarrow \mathbb{R} \\ y &\mapsto y & & \quad y \mapsto \mathbb{1}_{\{y \geq t - q_\varepsilon\}}. \end{aligned}$$

Dans la suite on prend $\varepsilon = 0.6$.

11. (♠) Entre $h_{0,1}$ et $h_{0,2}$, quelle fonction utiliseriez-vous pour réduire la variance de $\hat{\delta}_n$ à l'aide de la méthode de la variable de contrôle? Écrire l'estimateur $\hat{\delta}_n^{\text{cont}}$ associé.
12. (♠) Implémenter un code R qui fournit, pour $n = 1000$, l'estimation $\hat{\delta}_n^{\text{cont}}$, l'erreur quadratique moyenne de $\hat{\delta}_n^{\text{cont}}$ et un intervalle de confiance asymptotique bilatère pour δ au niveau 95%.

Pour $(Y_k)_{k \geq 1}$, une suite de variables aléatoires *i.i.d.* suivant g , on veut construire le meilleur estimateur de la forme

$$\hat{\delta}_n(\beta) = 1 - \frac{1}{n} \sum_{k=1}^n F(t - Y_k) - \langle \beta, \begin{pmatrix} Y_k - \mathbb{E}[Y] \\ \mathbb{1}_{\{Y_k \geq t - q_\varepsilon\}} - \mathbb{P}[Y \geq t - q_\varepsilon] \end{pmatrix} \rangle, \quad \text{avec} \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} \in \mathbb{R}^2.$$

$\langle \cdot, \cdot \rangle$ désigne le produit scalaire usuel de \mathbb{R}^2 , *i.e.*, $\langle U, V \rangle = U^T V$.

13. Montrer que

$$\text{Var}[\hat{\delta}_n(\beta)] = \text{Var}[\hat{\delta}_n] - \frac{1}{n} (2 \langle \beta, C \rangle - \langle \beta, \Sigma \beta \rangle), \quad \text{avec}$$

$$C = \begin{pmatrix} \text{Cov}[F(t - Y), Y] \\ \text{Cov}[F(t - Y), \mathbb{1}_{\{Y \geq t - q_\varepsilon\}}] \end{pmatrix} \quad \text{et} \quad \Sigma = \begin{pmatrix} \text{Var}[Y] & \text{Cov}[Y, \mathbb{1}_{\{Y \geq t - q_\varepsilon\}}] \\ \text{Cov}[Y, \mathbb{1}_{\{Y \geq t - q_\varepsilon\}}] & \text{Var}[\mathbb{1}_{\{Y \geq t - q_\varepsilon\}}] \end{pmatrix}.$$

14. Calculer explicitement Σ et vérifier qu'elle est inversible.

15. Montrer que

$$\beta^* = \arg \min_{\beta \in \mathbb{R}^2} \mathbb{V}ar[\hat{\delta}_n(\beta)] = \Sigma^{-1}C \quad \text{et} \quad \mathbb{V}ar[\hat{\delta}_n(\beta^*)] \leq \mathbb{V}ar[\hat{\delta}_n].$$

16. L'estimateur $\hat{\delta}_n(\beta^*)$ est-il préférable en terme de variance à un estimateur basé sur la méthode de la variable de contrôle utilisant $h_0 : y \mapsto h_{0,1}(y) + h_{0,2}(y)$? Justifier rigoureusement votre réponse.

17. (♠) Implémenter un code R qui fournit, pour $n = 1000$, l'estimation $\hat{\delta}_n(\beta^*)$, l'erreur quadratique moyenne de $\hat{\delta}_n(\beta^*)$ et un intervalle de confiance asymptotique bilatère pour δ au niveau 95%.

Méthode Monte Carlo n°4.

18. Soit $h \in L^2([0, 1])$. Montrer que pour une suite $(U_k)_{k \geq 1}$ de variables aléatoires *i.i.d.* de loi uniforme sur $[0, 1]$, on a

$$\mathbb{V}ar \left[\frac{1}{n} \sum_{k=1}^n h \left(\frac{k-1+U_k}{n} \right) \right] \leq \mathbb{V}ar \left[\frac{1}{n} \sum_{k=1}^n h(U_k) \right].$$

19. En déduire un nouvel estimateur $\hat{\Delta}_n$ de δ . Comment peut-on interpréter cet estimateur?

20. (♠) Implémenter un code R qui fournit, pour $n = 1000$, l'estimation $\hat{\Delta}_n$, l'erreur quadratique moyenne de $\hat{\Delta}_n$ et un intervalle de confiance asymptotique bilatère pour δ au niveau 95%.

21. (♠) Comparer l'efficacité relative des différents estimateurs de δ que vous avez proposés.

Exercice 2 (Bonus). Soient $m \in \mathbb{N}^*$ et $k \in \llbracket 2, m-1 \rrbracket$. Avec la densité g définie à l'Exercice 1 et G la fonction de répartition associée à g , on définit

$$\Psi(x) = \frac{m!}{(k-1)!(m-k)!} G(x)^{k-1} [1 - G(x)]^{m-k} g(x).$$

1. (♠) Implémenter un algorithme du rejet qui simule n réalisations suivant la densité Ψ .

2. (♠) Vérifier graphiquement que votre code est valide pour $m = 15$ et $k = 7$.